



燕山大学
YANSHAN UNIVERSITY

硕士学位论文

MASTER'S DISSERTATION

(学 术 学 位)

论文题名 高动态异构车联网络资源联合鲁
棒优化分配的研究

作者姓名 魏建帅

学科专业 控制科学与工程

指导教师 刘志新 教授

2024 年 6 月

扰模型如图 1-1 所示。该网络拓扑下车辆用户在某一载波信道上的干扰可以描述为： $\delta_i^k + \sum_{j \neq i} p_j^k g_{ij}^k < I_i^k$ ，其中， g_{ij}^k 为地面宏用户 j 在信道 k 上对车辆用户设备 i 的信道增益， p_j^k 为宏用户 j 的信息发射功率， δ_i^k 为背景噪声， I_i^k 为车辆用户 i 的在信道 k 上可正常通信时的最大可容忍的干扰阈值。在一些学术研究中，Zhou 等人^[19]开发了一种 5G 频谱动态共享方法，并提出了专用短程通信 (Dedicated Short-Range Communication, DSRC) 和 5G 频谱的共享架构，以实现沉浸式体验驱动的车载通信。Tran 等人^[20]提出了一种综合方法来应对多服务器 MEC 辅助网络中任务卸载和资源分配的挑战。结果表明，当频谱资源稀缺时，有效的信道复用至关重要^[21]。然而，这种方法通常会产生干扰，在车载通信场景中，信道复用造成的干扰往往会严重降低通信质量。为了处理中断概率约束，Xiao 等人^[22]假定信道状态信息 (Channel State Information, CSI) 可以通过估计获得。Chen 等人^[23]将中断约束条件转换为伯恩斯式不等式，以提出确定性优化问题。总之，现有工作解决了异构车联网络的鲁棒功率优化，但还未在高动态 MEC 辅助的车联网络的进行鲁棒功率优化。




图 1-1 复用技术下的车联网通信干扰模型

1.2.2 云计算与边缘计算场景

移动边缘计算 MEC 和移动云计算 (Mobile Cloud Computing, MCC) 是 5G 网络中崭露头角的两种新型架构，它们常应用于物联网设备的任务卸载过程中，特别在提供低延迟、高可靠性的计算服务方面发挥着关键作用。与低移动性的传统移动通信网络不同，当快速移动的车辆与不同的 MEC 服务器通信时，车辆高移动性下的多普勒效应给 C-MEC 通信带来了挑战。在具有动态特性的网络场景中，确定性信道状

态信息已不足以描述信道状态。传输过程中产生的多普勒效应会严重影响 CSI 的小范围衰减,导致信道快速变化。换句话说,所使用的 CSI 已经过时。为了描述多普勒频移对信道的影响,可以使用一阶高斯-马尔科夫过程 (First-order Gauss-Markov process)^[24]。为了提高低通信延迟和计算延迟的性能,车载设备的延迟容忍度和传输可靠性都有所降低。因此,必须提出更高的要求。在文献 [25] 中 Li 等人为了确保车载通信链路的可靠性,引入了中断概率约束。当指数积分函数的精确表达式存在时,有必要考虑近似闭式表达式,使其具有可操作性,从而降低计算复杂度。

在 C-MEC 车载网络中,拥有频谱资源的授权车辆直接与 RSU 通信。然而,在高密度车载网络中,稀缺的频谱资源并不充足^[26]。Zhou 等人开发了一种 5G 频谱动态共享方法,并提出了 DSRC 和 5G 频谱的共享架构,以实现沉浸式体验驱动的车载通信^[19]。总之,现有研究解决了云计算中的功率控制和计算资源分配问题,这有助于高动态环境下的车载网络中的 MEC。但是研究试图确保通信质量和延迟要求的较少。

1.2.3 无人机辅助车联网与轨迹优化

近来,空地一体化作为提高无线通信质量最可行的解决方案之一,引起了业界和学术界的广泛关注。人们对空地一体化通信领域进行了广泛的关注和研究^[27-29]。由于具有部署灵活、远程操作和中继能力强等特点,空中无人机 (Unmanned Aerial Vehicle, UAV) 被选为地面网络的辅助设备^[30]。然而,当无人机加入异构场景时,空地一体化通信网络将面临两大挑战。首先,当采用信道复用模式提高频谱效率时,多用户干扰是一个棘手的问题。特别是在不确定的信道环境下,多用户干扰会极大地影响通信的有效性和鲁棒性,因此实现有效的干扰管理是一个重大挑战。其次,空地一体化异构车载网络 (Air-Ground Heterogeneous Vehicular Network, AGHVN) 是分层的,蜂窝用户 (Cellular User Equipment, CUE) 和车辆用户 (Vehicular User Equipment, VUE) 分别作为领导者和跟随者。然而,蜂窝用户和车辆用户是不同的利益相关者,他们为了各自的利益而竞争。平衡各方利益是一项挑战。因此,空地一体化异构车载网络的广泛部署仍面临紧迫挑战。

一些作者重点研究了空地一体化网络架构设计和资源管理^[27, 31]。在异构蜂窝网络中,无人机被用来协助应急通信^[32]。在文献 [28] 中提出了一种为车辆用户动态分配频谱资源的控制框架,其中采用了 Lyapunov 优化理论。然而,尽管上述工作都重视提高 AGHVN 的性能,但将系统鲁棒性与资源分配相结合的研究却没有得到足够的重视。由于信道不确定性的存在,现有的资源分配策略很难实现鲁棒通信。因

隙资源分配来最大化系统的能量效率，并且考虑了双向车道的场景，无人机空中基站与地面基站同时帮助车辆进行任务卸载。随着逐渐驶离地面基站的车辆通信质量越来越差，无人机可以调整飞行姿态以靠近这部分车辆来提供任务卸载。然后通过积分变换将非凸的中断概率约束转化成简单可解的形式，通过泰勒展开将难以求解的无人机轨迹问题展开成凸问题。最后仿真结果验证了算法的有效性并通过对比展示了无人机轨迹规划方案效果优于其他两种方案。

本文的整体结构流程如图 1-2所示。

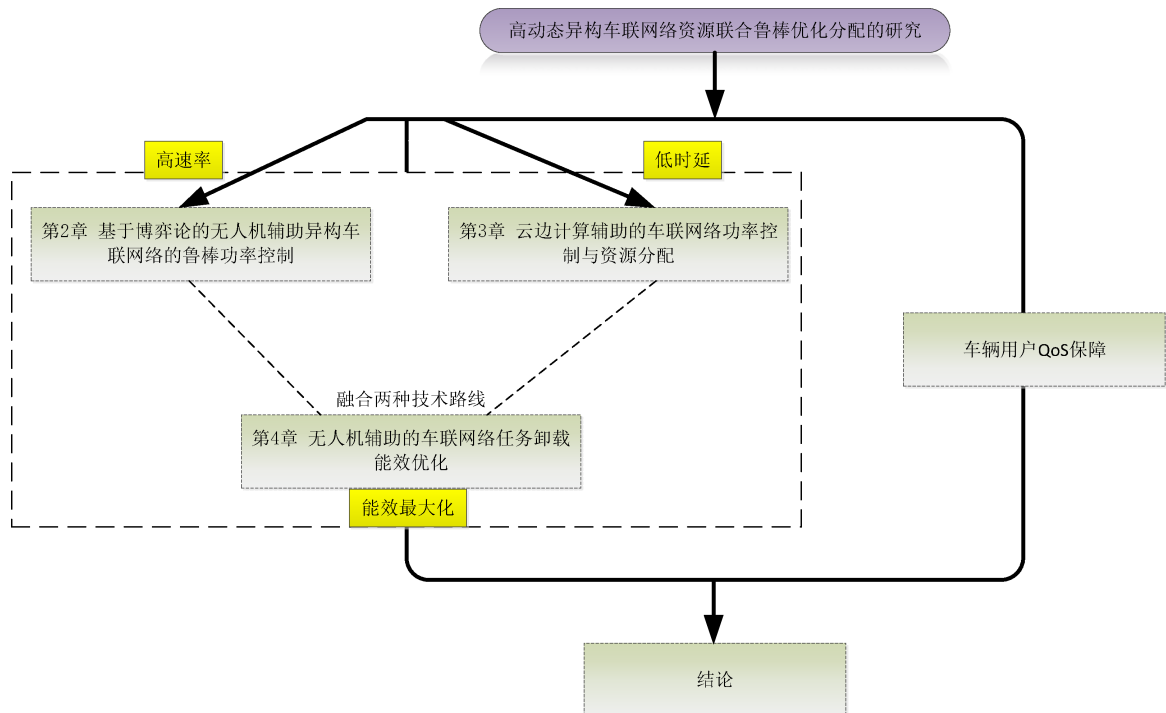


图 1-2 研究内容的总体结构安排

第 2 章 基于博弈论的无人机辅助异构车联网络的鲁棒功率控制

2.1 引言

作为智能交通系统 (Intelligent Traffic Systems, ITS) 最有前途的解决方案, 车联网 (Internet of Vehicles, IoV) 有望满足快速增长的需求, 如交通效率、驾驶体验和事故处理。然而, 由于车辆密度和用户需求的快速增加, 单小区网络的频谱效率变得较低^[34]。因此, 异构车联网络的部署已成为一种趋势^[35]。

近年来, 空地一体化作为提高无线通信质量的最可行的解决方案之一, 引起了工业界和学术界的广泛关注。由于无人机具有部署灵活、远程操作和中继能力, 选择空中无人机来辅助地面网络可提升网络效率^[30]。然而, 当无人机加入异构场景时, 空地综合通信网络将面临两大挑战。首先, 当使用信道复用模式来提高频谱效率时, 多用户干扰是一个棘手的问题。有效和鲁棒的通信在很大程度上受到多用户干扰的影响, 特别是在不确定的信道环境中, 因此实现有效的干扰管理是一个重大挑战^[24]。其次, 空地异构车辆网络 (AGHVN) 是分层的, 其中蜂窝用户 CUE 和车辆用户 VUE 分别充当领导者和追随者。然而, CUE 和 VUE 是不同的利益相关者, 他们为自己的利益而竞争, 平衡各方利益是一项挑战, 使用博弈论的决策方法可以有效地构建 CUE 和 VUE 之间复杂利益关系^[36]。因此, 空地一体化异构车载网络的广泛部署仍然带来紧迫的挑战。

本章提出了一种基于博弈论的无人机辅助异构车联网络的鲁棒功率控制方法, 以车辆用户与地面宏用户之间的博弈关系为核心, 制定了实时功率分配和定价策略以实现用户利益的最大化。

2.2 系统模型与问题描述

2.2.1 系统及信道模型

本章考虑了一种上行链路空地一体化通信场景, 在这种场景中, 众多车对无人机 (V2U) 小区覆盖在一个宏蜂窝之下。如图 2-1 所示, 无人机固定悬停并部署在交通拥堵路段, 负责接收其覆盖范围内车辆的信号并将其发送到基站 (Base Station, BS)。值得注意的是, 所有无人机都是双工的, 配备有接收天线和发射天线, 因此接收和发射过程可以同时完成。通信中的 CUE 和 VUE 集合分别索引为 $\mathcal{S}_0 = \{0\}$ 和

$\mathcal{S}_l = \{1, 2, \dots, N\}$ 。为了提高频谱利用率，实现多用户联合通信，V2U 通信重复使用了 CUE 的上行信道。但是会产生严重的多用户干扰，限制了信号链路的通信。如图 2-1 所示，信号链路 (蜂窝链路和同信道 V2U 链路) 和干扰链路 (CUE-V 链路、V-BS 链路和 V2U 干扰链路) 被区分开来。

假设无人飞行器的飞行高度为 H_n ，则 VUE_k 与 UAV_n 之间的距离为：

$$h_{k,n} = \sqrt{H_n^2 + (\|W_k - W_n\|)^2}, \quad k, n \in \mathcal{S}_l \quad (2-1)$$

其中 W_k 和 W_n 是 VUE_k 与 UAV_n 的位置信息，CUE 与 BS 之间的距离为：

$$h_{0,0} = \sqrt{H_0^2 + (\|W_0 - W_{BS}\|)^2} \quad (2-2)$$

其中， W_0 和 W_{BS} 为 CUE 和 BS 的位置， H_0 为 BS 上信号接收器的垂直高度。 VUE_k 与 BS 之间的距离为 $h_{k,0}$ ，CUE 与 UAV_n 之间的距离为 $h_{0,n}$ ， $h_{k,0}$ 和 $h_{0,n}$ 的表达式类似于 (2-1) 和 (2-2)。

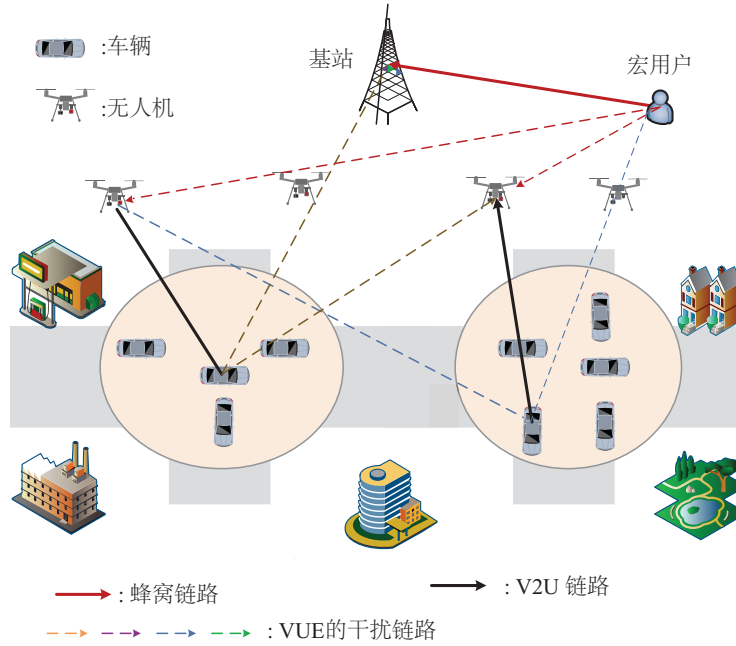


图 2-1 空地网络系统模型

蜂窝链路和同信道 V2U 链路的大规模衰落可分别表示为：

$$g_{0,0} = L_{0,0} h_{0,0}^{-\alpha} \quad (2-3)$$

$$g_{n,n} = L_{k,n} h_{k,n}^{-\alpha}, \quad k, n \in \mathcal{S}_l, k = n \quad (2-4)$$

其中， $L_{0,0}$ 和 $L_{n,n}$ 是蜂窝链路和同信道 V2U 链路的阴影衰减效应。 α 是路径损耗指数。虽然车辆与无人机之间的传输链路可视为借助无人机在道路上空进行的 LoS 通

信,但仍存在一些影响信道增益的因素,如通信终端的相对移动、信道估计误差以及不可避免的信道不确定性。因此,小尺度衰落不容忽视。根据文献 [24],它遵循截断指数分布。为了描述信道增益的不确定性,引入了一个参数 G , G 是一个独立的同分布随机变量,其概率密度函数为 $f_G(x) = e^{-x}$ 。信号链路 n 的实时信干噪比 (Signal to Interference plus Noise Ratio ,SINR) 可表示为:

$$\gamma_n(p_n) = \frac{p_n G g_{n,n}}{I_n}, k, n \in \mathcal{S}_l \quad (2-5)$$

其中, $g_{n,n}$ 是给定时隙内的估计增益。同信道 V2U 链路 n 的干扰可视为测量值,其表达式为:

$$I_n = p_0 g_{0,n} + \sum_{k=1, k \neq n}^N p_k g_{k,n} + \delta^2, \quad k, n \in \mathcal{S}_l \quad (2-6)$$

其中, p_k 表示第 k 个 VUE 的传输功率。 p_0 是 CUE 的传输功率。 δ^2 是噪声干扰。

为处理不确定参数 G , 确保 V2U 通信质量, 引入了以下中断概率约束,

$$\Pr \{ \gamma_n \leq \gamma_{th} \} \geq 1 - \varepsilon, \quad n \in \mathcal{S}_l \quad (2-7)$$

其中, $\Pr\{\cdot\}$ 为概率约束, γ_n 表示第 n 个同频 V2U 链路的瞬时 SINR。 γ_{th} 是给定的目标 SINR 阈值, ε 是中断概率阈值, $\varepsilon \in (0, 1)$ 。

为了考虑不确定的信道增益, 并使用遍历容量来显示网络性能,

$$R_{er} = \int_0^\infty W \log(1 + \gamma_n) \Pr(\gamma_n) d(\gamma_n) \quad (2-8)$$

其中, W 是复用信道的带宽, $\Pr(\gamma_n)$ 是 γ_n 的概率分布函数。根据詹森不等式可知,

$$\begin{aligned} \mathbb{E} W \log(1 + \gamma_n) &= \int_0^\infty W \log(1 + \gamma_n) \Pr(\gamma_n) d(\gamma_n) \\ &< W \log(1 + \mathbb{E} \gamma_n) \\ &= W \log(1 + \bar{\gamma}_n) \end{aligned} \quad (2-9)$$

其中 $\bar{\gamma}_n = \mathbb{E} \left\{ \frac{p_n G g_{n,n}}{I_n} \right\} = \frac{p_n g_{n,n}}{I_n}$, 是香农容量是遍历容量的上限, 通过信道编码技术可以使遍历容量接近上限。因此, 根据香农定理计算出的 VUE 的确定性等效传输速率为:

$$R_n = W \log(1 + \bar{\gamma}_n(p_n)), \quad n \in \mathcal{S}_l \quad (2-10)$$

2.2.2 博弈论问题的描述

在空地一体化异构的车载网络 (AGHVN) 中, 频谱所有者 CUE 可以对干扰进行定价, 并将 VUE 的收费作为其利润。在 V2U 小区中, VUE 的效用是传输速率与购

2.4 算法与仿真实验

2.4.1 斯塔克尔伯格博弈的迭代算法

本节提出了一种基于斯塔克尔伯格博弈的鲁棒资源分配算法来解决优化问题 (2-13) 和 (2-14)。该算法如下所示：

算法 2-1 基于斯塔克尔伯格博弈的鲁棒资源分配算法

Step1: 开始。

Step2: 初始化功率 $p_n(0)$ 和干扰价格 $c_n(0)$

Step3: 设置 $t = 1$, $T = 20$, $p_n(0)$ 为可行区域内的任意一点, 且 $0 \leq p_n(0) \leq p_{n,\max}$ 。

Step4: 设置 $\lambda_n > 0$, $\mu_n > 0$, $K_\lambda > 0$, $K_\mu > 0$

Step5: 根据 (2-19) 更新乘子 λ_n 。

Step6: 更新第 n 个 VUE 收到来自 BS 的干扰价格, 然后根据 (2-22) 计算 $p_n^{(t+1)}$

Step7: BS 收到 VUE 用户的最优响应函数和反馈信息后, 根据 (2-29) 更新乘子 $\mu_n^{(t+1)}$

Step8: 根据 (2-30) 计算干扰价格 $c_n^{(t+1)}$ 。

Step9: 重复执行 Step5 至 Step8。

Step10: 设置 $t = t + 1$

Step11: 若满足 p_n 和 c_n 收敛并且 $t < T$, 结束。

前面各小节的分析总结见算法 2-1。值得注意的是, 由于每个车辆 VUE 之间不存在信息交换, 因此, 算法 2-1 是一种分布式算法, 与集中式算法相比, 其可以降低计算复杂度。信令开销定义为一次迭代中信息互变化的次数。BS 作为领导者, 首先向 VUE 发送一条信息, 其中包含 BS 的策略。然后, 每个 VUE 做出反应, 即回复一条信息给 BS。因此, 算法 2-1 的信号开销为 $2N$, 其中 N 是 VUE 的数量。计算复杂度为 $\mathcal{O}(N)$ 。在集中式算法中, 每个 VUE 都需要来自其他 VUE 的状态信息。信令开销增加到为 $N^2 + N$, 计算复杂度为 $\mathcal{O}(N^2)$ 。通过以上分析, 与集中式算法相比, 本算法具有更低的复杂度和更少的信号开销。

2.4.2 仿真分析

本节将进行数值模拟, 以评估基于鲁棒的斯塔克尔伯格博弈的资源分配算法的性能。在半径为 500m 的 BS 覆盖范围内, 模拟了一个包含 1 个 CUE 和 9 个 V2U 集群的简化车辆通信模型, 用于模拟异构通信场景, 其中无人机用于悬停道路上方为

VUE 提供任务卸载，CUE 与 BS 在覆盖范围内正常通信。表 2-1 列出了相应的系统仿真参数。

表 2-1 系统仿真参数

符号	参数	数值
R	基站的通信范围	500 m
H_n	无人机的巡航高度	30 m
H_0	基站上信号接收器的垂直高度	30 m
W	信道带宽	10 MHz
L	阴影衰落效果	0.9
α	路径损耗指数	1.4
δ^2	噪声方差	-30 dBm
$p_{i,max}$	车辆最大发射功率	0.01 W
I_{th}	干扰阈值	10^{-3}
ε	中断概率阈值	0.1

基于鲁棒斯塔克尔伯格博弈的资源分配算法的收敛性能如图 2-2 和图 2-3 所示。




图 2-2 功率收敛性能

九个 VUE 的发射功率用 $p_1 - p_9$ 表示，价格用 $c_1 - c_9$ 表示。在图 2-2 中，VUE 的发射功率在第七步收敛到最优值，VUE 的非均匀价格逐渐趋于稳定，最终达到收

敛。因此，图 2-2 和图 2-3 中的结果表明，所提出的基于鲁棒博弈的资源分配算法是快速且有效的。




图 2-3 价格收敛性能

为了进一步验证所提算法的性能，图 2-4 和图 2-5 完成了对系统鲁棒性和传输速率的验证。在复杂的通信场景中，严重的多用户干扰会影响用户的信号传输，甚至造成中断。




图 2-4 中断概率对此

如图 2-4 所示，当真实的阈值 ϵ 在 0.1 到 0.6 之间变化时，用户的实际中断概率总是小于给定的阈值。结果证实，本章方法不仅实现了有效的干扰管理，还保证了

传输的鲁棒性。说明本文提出的基于鲁棒博弈的算法在信道不确定性较高的实际场景中更加稳定。




图 2-5 传输速率对比

如图 2-5 所示，在不同的方案对比时，博弈论方法中的价格是实现 VUE 之间平衡的关键变量。当一个 VUE 通过增加功率来提高传输速率时，它将受到来自 BS 的更多干扰费的惩罚。通过多轮博弈，每个用户都达到了自己最满意的状态，因此用户的传输速率得到了很好的平衡，也高于文献 [39] 中使用的方法和使用二分法的传输速率。

图 2-6 表示了三种不同的方案下，每辆车的平均传输速率。




图 2-6 不同车辆时系统的平均传输速率

处理 MEC 层无法处理的对延迟不敏感的大规模数据。这种网络结构缩短了传输时间，并提供了大量的计算资源。

(2) 采用一阶马尔可夫过程来处理 C-MEC 车辆网络环境高速移动引起的信道不确定性。使用概率约束保证了车辆的 QoS 并采用伯恩斯坦近似法逼近大规模动态车载网络环境中的非凸的概率约束。

(3) 建立了一种处理传输任务的高效结构，并提出了一种鲁棒的功率控制和任务卸载调度算法，以接近最优解。在 C-MEC 车辆网络下，该算法可在低运算复杂度下得到车辆的发射功率与计算资源分配。模拟仿真验证了系统卸载效用的提高。

3.2 系统模型与问题描述

本文研究的 C-MEC 车载网络如图 3-1 所示，由 MEC 层和云计算层分层计算卸载架构组成。众多车辆在 RSU 的覆盖范围内被划分为多个地理区域，每个 RSU 下覆盖一个小区，每个 RSU 配备一台 MEC 服务器，为车辆提供计算卸载服务。将移动系统中的两组车辆和 MEC 服务器分别记为 $\mathcal{V} = \{1, 2, \dots, V\}$ 和 $\mathcal{M} = \{1, 2, \dots, M\}$ 。高速移动无线通信链路称为 V2RSU (V2R) 链路，固定有线连接链路称为 RSU 到云 (RSU-to- Cloud, R2C) 链路。详细的卸载过程描述如下。首先，车辆通过无线接口向云发送卸载请求信息，其中包括所需的通信资源、任务 ID 和提交时间，以及任务的最大可容忍服务时间。其次，MEC 服务器根据接收到的请求信息进行调度，包括任务上传服务器和任务计算服务器。最后，任务上传后，任务被推送到服务器队列中，直到服务器执行任务。




图 3-1 C-MEC 系统模型图

3.2.1 通信模型

由于车辆移动速度快，通信模式与传统的蜂窝通信不同。因此，很难直接获得 CSI。其中，RSU 仅能准确获取车辆到 RSU 链路的大尺度衰落 L^2 ，而小尺度衰落 h 受多普勒效应引起的快速信道变化影响较大。可以假设 CSI 是通过信道估计获得的，因此，可以利用一阶高斯 - 马尔可夫过程^[47] 对每个传输时间间隔内的信道估计 h 建模如下，

$$h = \xi \tilde{h} + \sqrt{1 - \xi^2} \zeta \quad (3-1)$$

假设信道增益 \tilde{h} 表示对 h 的估计，小尺度快衰落 \tilde{h}^2 是指数分布，并具有单位平均值^[48]。此外， $\xi \in (0, 1)$ 表示 V2R 链路上的相关系数， ζ 表示信道增益，其复高斯分布为 $\zeta \sim CN(0, \delta^2)$ ，与 \tilde{h} 无关。系数 $(0 < \xi < 1)$ 量化了两个连续时隙之间的信道相关性，假设所有车辆都存在相同的时间相关系数 ξ 。Jakes 的衰落信道统计模型^[47] 指出： $\xi = J_0(2\pi f_{max} T_s)$ ，其中 J_0 是第一类零阶贝塞尔函数。 $f_{max} = \bar{v} f_c / c$ 是最大多普勒频率，其中 \bar{v} 表示车辆速度， f_c 表示 5.9 GHz 的载波频率， $c = 3 \times 10^8 \text{m/s}$ ， T_s 是周期反馈延迟。发射车和 RSU 都知道实际的 ξ 。

根据上述讨论，从第 i 个车辆发射器到第 j 个接收器的第 k 个时隙内，有效链路和干扰链路的移动 V2R 信道功率增益用如下表达式表示：

$$G_{i,j}^k = \tilde{g}_{i,j}^k + \hat{g}_{i,j}^k \quad (3-2)$$

其中 $\tilde{g}_{i,j}^k = L_{i,j}^2 \tilde{h}_{i,j}^2 \xi_{i,j}^2$ ， $\hat{g}_{i,j}^k = L_{i,j}^2 (1 - \xi_{i,j}^2) \zeta_{i,j}^2$ ， $L_{i,j}^2$ 表示第 k 个时隙的大规模衰减效应，包括阴影衰减和从道路上第 i 个车辆发射器到第 j 个接收器的路径损耗。此外， $\hat{g}_{i,j}^k$ 是观测值， $\tilde{g}_{i,j}^k$ 表示指数随机变量，参数为 $\frac{1}{L_{i,j}^2} (1 - \xi_{i,j}^2)$ ，该参数基于文献^[26]。

为了提高频谱利用率并实现多车联合通信，V2R 通信重复使用同一上行链路信道。换句话说，车辆 j 和车辆 i 共享同一个上行链路信道，从而导致它们之间产生干扰。在这种情况下，V2R 链路的信干噪比 SINR 计算公式为，

$$\gamma_i(\mathbf{p}) = \frac{p_i g_{i,m}}{\sum_{j=1}^M p_j g_{j,m} + \sigma^2}, m = 1, 2, \dots, M, i \in \mathcal{V}_m \quad (3-3)$$

其中， $g_{i,m}$ 表示 i_{th} 车辆对其集群 RSU 的功率增益，而 $p_j g_{j,m}$ 表示其他集群车辆对当前 RSU 的干扰。

$$R_i(\mathbf{p}) = \log_2(1 + \gamma_i(\mathbf{p})) \quad (3-4)$$

当输入参数为 $d_{i,up}$ 时，车辆 i 向上行链路发送任务输入时的传输时间定义为 $t_{i,up}$ 。

表 3-1 系统仿真参数

符号	参数	数值
R_a	基站的通信范围	300 m
f_c	载波频率	5.9 GHz
T	车辆的 CSI 反馈周期	1 ms
v	平均车速	30 m/s
L	阴影衰落效果	0.9
θ	路径损耗指数	3
δ^2	噪声方差	-30 dBm
$p_{i,max}$	最大功率	0.01 W
I_{th}	干扰阈值	10^{-3}
ϵ_1	中断概率阈值	0.1
ϵ_2	中断概率阈值	0.1




图 3-2 功率收敛性能

图 3-4 显示了联合优化时系统总效用的收敛情况。从图中可以看出，网络系统总效用的收敛趋势与功率分配和计算资源分配有关。观察到这一现象是合理的，因为方程 (3-10) 给出了 U 的定义。随着功率矢量 \mathbf{p} 的增加， R_i 也会增加，从而导致其单调递减。因此，随着迭代次数的增加，效用值的增量会越来越小，最终导致

效用值趋于稳定。当功率矢量 \mathbf{p} 和分子部分的执行效用 $t_{i,exe}$ 随着计算资源矢量 \mathbf{f} 的增加而成反比减少时， U 的分母会减少，分子会随着矢量 \mathbf{f} 的增加而增加。




图 3-3 分配给 RSU 的计算资源分配的收敛.




图 3-4 系统总效用的收敛

在支持 MEC 的车载云系统中，有必要考虑车辆的移动性。接下来探讨了车辆移动对系统性能的影响。可以假设在指定时间段内车辆速度的任何变化都是微不足道的。在系统中模拟了车速不断提高时的对比实验，如图 3-5 所示，通信过程中的车速分别设置为 20 m/s、30 m/s、40 m/s、50 m/s 和 60 m/s。这种配置导致一个事实，随着车辆速度的提升，系统性能会下降，因为车速越快，网络内的多普勒频移越大，

这会导致信道不确定性增加，效用值随之下降。

为了进一步明确速度引起的多普勒频移对系统性能的影响，图 3-6 描述了不同 ε_1 值下的每辆车相同速度与不同速度的时候对总效用的影响，从图中可以看出随着 ε_1 的改变，系统效用也随之变化，在每辆车速度不同时的效用要高于所有车相同的速度，表征了提出的方法在复杂的动态车辆环境下具有较高的鲁棒性




图 3-5 不同速度下系统总效用的对比




图 3-6 不同 ε_1 下系统总效用的变化

在计算资源分配方面，选择默认的任务输入大小为 $d_u = 420\text{KB}$ (可参考 [52])。它将展示本章提出的算法的收敛性能。仿真结果表明，本章提出的方法优于三种对

比方案。对比方案描述如下：

(1) 独立卸载和功率控制 (简称 “IOP”), 即车辆独立执行功率控制和计算资源分配, 而不考虑彼此的最优值。

(2) 在无车辆功率控制 (简称 “Without-VPC”) 情况下, 车辆的发射功率设定为卸载期间的平均功率。

(3) 无计算资源分配 (表示为 “Without-CRA”), 即在卸载过程中将云的计算资源分配设为固定值。

图 3-7 显示了不同情况下系统总效用的迭代收敛情况, 图中显示鲁棒联合优化性能优于其他三种方案。从图中可以看出, 四种方法在迭代后期都收敛到了一个稳定的值, 其中本章提出的方案的性能最好。

为了反映更真实的情况, 每辆车所需的 CPU 任务负载 (Megacycles) 往往不同, 因此需要将五辆车的 CPU 任务负载 (Megacycles) 分别设置为 1600、1700、1800、1900 和 2000。




图 3-7 不同方案下系统总效用的收敛

从 3-7 可以看出, 随着迭代次数的增加, 车辆的平均系统效用逐渐发生变化并趋于稳定。在独立的优化过程中, 首先进行计算资源分配, 此时不知道最优的功率分配, 而使用功率与计算资源交替优化的方式, 每次迭代都可以得到相应的最优值。单独优化就是首先优化功率 p , 得到结果后, 将结果用于计算资源的优化, 然后对计算资源进行优化, 最终得到系统的效用。但是如果使用的是联合优化, 那么两个变量都能取到最优值。

图 3-8 中绘制了不同任务输入大小 d_u 时四种对比方案的平均系统效用。图 3-9 显示了不同 f_{total} 时的系统总成本比较。

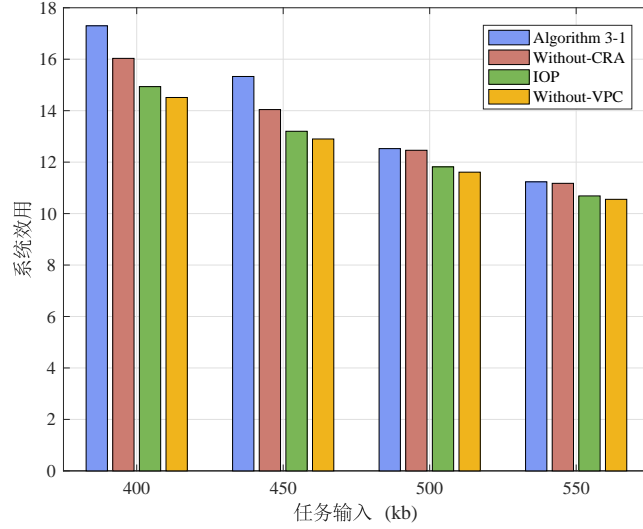


图 3-8 不同输入数据 d_u 下的系统效用




图 3-9 不同计算能力约束下的 f_{total} 系统效用

从图 3-8 中可以看出，所有方案的平均系统效用都随着任务输入量的增加而降低。图中还显示，其他方案的性能增益也有类似的趋势。这一现象是合理的，因为根据 (3-10) 中 U 的定义，工作量的增加会对系统性能产生负面影响。在图 3-9 中，由于云的计算能力有限，当计算能力较小时，系统效用较小。从图 3-10 中可以清楚地看到，当数据规模增大时，系统效用较小。当数据规模较大时，计算任务需要更

多的上传时间。




图 3-10 不同计算数据 $c_{i,e}$ 下的系统效用

3.5 本章小结

本章研究了车载网络中云辅助 MEC 的鲁棒功率控制和任务卸载的新方法。优化方案的目的是在最大化效用的同时保证车辆的 QoS。由于信道存在不确定性，优化受到传输速率、计算通信延迟和信道复用带来的共信道干扰概率形式的限制。最初的优化问题被表述为鲁棒性功率控制和任务卸载调度问题，很难解决。这里应用了 SCA 技术，将变量耦合的 NP 难问题转化为可处理的凸问题。鲁棒功率控制和任务卸载调度算法用于开发可行的解决方案。仿真结果表明，本章提出的算法得到了近似最优解。与现有方法相比，系统平均卸载效用得到显著改善。

第4章 无人机辅助的车联网任务卸载能效优化

4.1 引言

在前一个章节中，主要研究了车联网的地面通信网络，然而随着城市化建设的加深，道路网络越来越复杂，车辆的地面通信网络容易受到建筑物的遮挡，同时地面基站也难以覆盖越来越多的通信车辆，通过引入移动无人机作为空中基站可以有效解决这一难题^[53, 54]，其中文献^[55]便引入了无人机作为空中基站辅助地面用户更加高效通信的系统。本章研究了作为前沿通信技术的无人机作为空中基站辅助车联网通信，并着重考虑了更加实际的双向车道的场景。无人机具有灵活部署成本低与高机动性的特性^[56–58]，可以更加有效的作为空中基站辅助地面车辆进行任务卸载，并且更好的满足车辆用户的 QoS 需求^[59]。由于本文考虑的车辆环境均为高速移动场景，固定轨迹的无人机难以适应实时变化网络拓扑环境，因此实时优化无人机的飞行的航迹有助于提高辅助车辆通信的服务质量。此外，无人机飞行与作为空中基站时均为耗能设备，所以整个系统的能量效率也应备受关注。

综上所述，本章研究了一个类似于文献^[60]中的双向车道下无人机辅助车辆网络能效最大化的场景，文献^[61–64]中研究探讨了关于双向车道通信的好处，车辆高速行驶于双向的高速公路上，地面基站位于道路的一侧。随着对向行驶的车辆的高速移动，向右行驶的车辆会逐渐驶出当前通信小区，无法与地面基站进行通信，此时，无人机可作为空中基站以接收车辆通信信号。无人机以固定的高度平行于道路进行无障碍飞行，本章提出的算法可以实时的判断当前时隙车辆如何选择通信对象使得系统的能量效率最大化。本章的贡献可以做出如下总结：首先，本章提出了一种无人机辅助双向车道场景下规划无人机航迹的系统模型，为了提高整个网络系统的能量效率，采用丁克尔巴赫方法 (Dinkelbach Method) 使得系统在最小的能耗下可以最大化总吞吐量，为了保证地面车辆用户的服务质量，在优化问题中建立了时变的车辆移动模型下的概率约束，并以多普勒效应描述信道的不确定性。

4.2 系统模型与问题描述

本章考虑了一个空地一体化网络，其中车辆行驶于双向的高速公路上，无人机从基站附近起飞，作为地面车辆的空中基站进行任务的卸载，基站位于坐标原点，高度为 h_0 ， D_R 代表了路边单元的覆盖范围的半径长度，可以将车辆运动建模为常速度运动模型^[65]。可以规定向右为正方向，定义车道索引 $L = 1$ 为车辆向右行驶，

$L = -1$ 为向左行驶。由于基站位置固定，随着时间的推移，不可避免地存在一个方向的车辆会远离基站，势必影响其通过基站获取信息，此时，无人机向着基站的右方飞去，进而帮助远离基站的车辆获取需要的信息。为了决策道路上的车辆需要从无人机还是基站获取信息，根据由一阶马尔可夫过程预测到车辆到基站的信道状态信息与车辆与空中基站无人机视距链路得到的信道状态信息分别得出车辆与两个数据中中心通信的信噪比 (Signal to Noise Ratio, SNR)，车辆会选择信噪比较大的一方请求资源， $x_m[t] = 1$ 为车辆选择无人机进行通信，反之车辆选择地面的基站进行通信。

无人机的飞行周期 \mathcal{T} 被离散划分为足够多相等的 T 个时隙，每个时隙 t 被认为是足够小的，即 $\mathcal{T} = Tt$ ，时隙的集合为 $\mathcal{T} = \{1, 2, \dots, t, \dots, T\}$ ，在时隙 t 内，无人机的水平坐标为 $q_U[t] = \{\pi_u[t], \varpi_u[t]\}$ ，无人机在距离路面高度为 H 进行无障碍飞行，其飞行最大速度为 V_{max} ，车辆的集合为 $\mathcal{M} = \{1, 2, \dots, m, \dots, M\}$ ，车辆 m 的初始水平位置为 $q_m[0] = \{\pi_0, \varpi_0\}$ ，假设车辆以速度 v_m 匀速直线行驶，根据之前定义的车道索引可以得出车辆 m 在第 t 时刻的水平位置变化为 $\pi_m[t] = \pi_0 + lv_mt$ ，车辆 m 的水平位置 $q_m = \{\pi_m[n], \varpi_0\}$ 根据位置信息即可得到在第 t 时刻的距离信息车辆 m 在 t 时隙与路边单元的距离为 $d_{m,R}[t] = \|q_m[t] - q_R\| = \sqrt{\pi_m[t]^2 + \varpi_0^2 + H^2}$ ，车辆 m 在 t 时隙与无人机的距离为 $d_{m,U}[t] = \|q_m[t] - q_U[t]\| = \sqrt{(\pi_m[t] - \pi_u[t])^2 + (\varpi_m[t] - \varpi_u[t])^2 + H^2}$ ，系统模型如图 4-1 所示。




图 4-1 无人机辅助车联网系统模型

首先，展示了不同时间隙下的系统总能效最大时的无人机轨迹优化如图 4-2 所示，其中黑色箭头代表车辆向右行驶为正方向，规定无人机从固定起点飞行至固定终点，可以发现，当任务时间足够时，无人机会倾向于贴近远离基站的车辆为其服务。图 4-3 展示了无人机在每个时间隙的速度情况，当车辆需要无人机辅助时，无人机会放慢速度甚至悬停以匹配车辆速度为其服务。




图 4-2 无人机轨迹优化.




图 4-3 无人机速度

在验证了算法的优化轨迹的性能之后，进一步验证了所提方案在不同参数下的性能水平。图 4-4 显示了在使用不同的 θ 时，在不同时间隙，它们对系统的能效产生

了不同的影响。其中 θ 是描述车辆任务在无人机端与路边单元端的相对能量成本的系数。当 θ 发生变化时，系统效用也会发生变化。较高的参数代表了更加关注无人机的飞行能耗。整体的系统能效随着无人机飞行时间 T 的增加而减小，因为更长的时间足够无人机遍历更多的车辆以获得更好的信道并节省能量。此外，还发现较低的 θ 会带来较高的能效。这是因为当认为无人机的能耗相对重要时，车辆往往会增加功率以传输更多数据，从而提高能效。




图 4-4 不同的参数 θ 下的能效

在图 4-5 中，对比了固定位置的悬停方案 (Fixed Position Hovering Solution, FPHS)，固定轨迹的方案 (Fixed Trajectory Solution, FTS) 与优化无人机轨迹方案 (Optimized Path Trajectory Solution, OPTS) 三种无人机通信方案在不同飞行周期 T 下的能效表现。

从整体趋势来看，随着无人机飞行时间的延长，各方案的能效均逐渐趋于稳定，这是因为无人机有了更充足的时间以合适的功率传输数据。进一步观察发现，OPTS 和 FPHS 两种方案适用于不同的场景。尽管 OPTS 算法复杂度较高，但它在较短的飞行周期内能够实现更高的能效，显示出更好的时效性。这意味着在需要快速响应的场合，OPTS 是一个优势明显的选择。相对而言，当飞行周期较长时，FPHS 的能效虽然略逊于 OPTS，但由于其算法复杂度较低，实现起来更为简单。因此，在时间要求不那么严格的环境中，FPHS 可能是一个更经济的解决方案。至于 FPHS 方案，其能效表现相对较差。这是因为无人机在固定位置悬停，导致与地面车辆之间的距离较远，从而影响了数据传输的效率。此外，随着飞行周期的增加，OPTS 和 FPHS 之间的能效差距逐渐缩小。这主要是因为当飞行周期较短时，OPTS 中的数据传输

时间受限，车辆需要在有限的时间内向无人机发送信息，这导致了能效的降低。而随着飞行周期的延长，OPTS 有更多的时间来优化数据传输过程，从而提高了能效。




图 4-5 不同的方案下的能效

下图展示了三种方案在不同参数 θ 下的对比。在图 4-6 中，探究了 OPTS、FHCS 和 FTS 三种无人机通信方案的能效如何随参数 θ 的变化而变化。




图 4-6 不同的参数 θ 在不同的方案下的能效

图 4-6 中 θ 是一个关键的参数，它反映了无人机的飞行能耗与通信能耗之间相对能量成本的比重。当 θ 值较大时，无人机的飞行能耗成为整体能耗的主导因素。观察图中趋势，可以发现，随着 θ 的变化，三种方案的能效都经历了一个明显的下降

过程，并在 $\theta = 0.8$ 时达到最低点。随后，能效呈现出略微上升的趋势。当 θ 较小时，意味着无人机的飞行能耗在整体能量成本中的占比相对较低。因此，无人机可以更加积极地传输数据，从而提高了整体的能效。相反，当 θ 较大时，无人机的飞行能耗成为主导，这限制了其数据传输的能力，进而影响了能效。综上所述，参数 θ 通过影响无人机的飞行能耗与通信能耗之间的能量成本分配，进而影响了三种无人机通信方案的能效表现。在实际应用中，需要根据具体场景和需求来选择合适的 θ 值，以优化无人机的通信效率。

最后图 4-7 对比了双向车道场景与单向车道场景，在道路上车辆总数相同的情况下，由于双向车道场景可以更大限度的发挥路边单元与空中基站的协同作用，带来了更高的能效。




图 4-7 双向车道与单向车道能效对比

4.5 本章小结

本章提出了一种高效的空地一体化的无人机辅助双向车道的车辆通信方案。通过优化车辆的发射功率与无人机的飞行轨迹，以及时隙的分配，可以使得系统的能效最大化，并通过概率约束，保证了车辆通信的服务质量，通过调整不同的参数 θ ，可以发现其可以影响系统的能效。通过对比不同的无人机飞行方案，能看到优化轨迹的无人机方案最佳。同时，本章也研究了更加现实的方向车道的场景路边单元与服务器常常部署于道路的一侧，那么在双向车道的场景下，总有一向行驶的车辆势必会远离路边单元，从而造成通信的困难，使用无人机辅助其通信可以较好的解决该困难。